

从三维重建到世界模型的技术路径综述

几何、辐射场与显式表示

3D_Reconstruction_ing 项目笔记

2026 年 7 月 6 日

摘要

本综述基于 3D_Reconstruction_ing 仓库中的文档与代码，系统梳理从传统三维重建到面向世界模型（World Model）的 3D/360 表示技术路径。文章从几何层（几何一致性）、辐射场层（NeRF 及其变体）、显式高效表示层（3D Gaussian Splatting / 4DGS），以及语义与世界记忆接口四个层面展开，给出关键数学公式与算法要点，为后续工程实践文档与实验提供理论背景。

目录

1 引言：三维重建与世界模型	2
2 几何层：多视图几何与 COLMAP	3
2.1 针孔相机模型与坐标变换	3
2.2 对极几何与本质矩阵	3
2.3 三角化与 Bundle Adjustment	3
2.4 多视图立体（MVS）与稠密重建	4
3 辐射场层：NeRF 与体渲染	4
3.1 连续辐射场表示	4
3.2 体渲染积分与离散近似	4
3.3 训练目标与变体	5
4 显式高效表示：3D Gaussian Splatting 与 4D 扩展	5
4.1 3D 高斯表示与参数化	5
4.2 Splatting 与可微渲染	6
4.3 4DGS 与动态场景	6

1 引言：三维重建与世界模型	2
5 语义层与世界记忆接口	6
5.1 2D 语义分割与像素级监督	6
5.2 3D 语义融合：从图像到点云	7
5.3 语义 NeRF 与语义 3DGS	7
6 统一静态场景状态与世界模型视角	7
7 结语	8

1 引言：三维重建与世界模型

三维与全景重建 (3D / 360 Reconstruction) 关注从多视角图像或视频中恢复世界的几何结构与全景语义。在世界模型视角下，我们期望的不只是离线重建一个静态场景，而是构建一个可查询、可渲染、可推理的空间表示，用于支撑导航、编辑、理解与生成等多种下游任务。

本仓库的总体目标可以概括为：

围绕 Mip-NeRF 360 等真实世界数据，搭建从 COLMAP $\rightarrow$ Nerfstudio $\rightarrow$ 3DGS / 4DGS 的动手实践与技术验证管线，为“世界模型”的 3D / 360 表示打基础。

从技术栈角度，核心可拆解为三层：

1. 几何层 (Geometry / SfM / MVS)：

估计相机位姿与稀疏/稠密点云，保证几何与物理一致性。

2. 辐射场层 (Radiance Field / NeRF)：

学习连续体积场函数 $f(\mathbf{x}, \mathbf{d})$ ，从任意视角渲染高质量图像。

3. 显式高效表示层 (3DGS / 4DGS 等)：

用高斯云等显式结构替代纯 MLP 体渲染，在保证质量的前提下提升渲染效率与可编辑性。

在此之上，再叠加语义层与统一的场景状态 (Scene State)，构成可查询、可组合的世界记忆。

2 几何层：多视图几何与 COLMAP

2.1 针孔相机模型与坐标变换

在经典多视图几何中，针孔相机模型将 3D 点 $\mathbf{X} = (X, Y, Z)^\top$ 映射到图像平面像素 $\mathbf{p} = (u, v)^\top$ ：

$$\lambda \begin{bmatrix} u \\ v \\ 1 \end{bmatrix} = \mathbf{K} \begin{bmatrix} \mathbf{R} & \mathbf{t} \\ \mathbf{0}^\top & 1 \end{bmatrix} \begin{bmatrix} X \\ Y \\ Z \\ 1 \end{bmatrix}, \quad \mathbf{K} = \begin{bmatrix} f_x & 0 & c_x \\ 0 & f_y & c_y \\ 0 & 0 & 1 \end{bmatrix}, \quad (1)$$

其中 $\mathbf{R} \in SO(3)$ 、 $\mathbf{t} \in \mathbb{R}^3$ 为相机外参， $\mathbf{K}$ 为内参， λ 为尺度因子。当考虑径向/切向畸变时，通常在像平面上先对归一化坐标做畸变矫正，再乘以内参。

2.2 对极几何与本质矩阵

在两视图情形下，空间点 $\mathbf{X}$ 在两个相机中的像素分别为 $\mathbf{p}_1, \mathbf{p}_2$ （齐次坐标），则存在本质矩阵 $\mathbf{E}$ 与基础矩阵 $\mathbf{F}$ 使得：

$$\mathbf{p}_2^\top \mathbf{F} \mathbf{p}_1 = 0, \quad \mathbf{F} = \mathbf{K}_2^{-\top} \mathbf{E} \mathbf{K}_1^{-1}, \quad \mathbf{E} = [\mathbf{t}]_{\times} \mathbf{R}, \quad (2)$$

其中 $[\mathbf{t}]_{\times}$ 为由平移向量 $\mathbf{t}$ 构造的反对称矩阵。在 COLMAP 等 SfM 系统中，通常使用带 RANSAC 的 8 点或 5 点算法从匹配点对中估计 $\mathbf{F}/\mathbf{E}$ ，再分解得到相对位姿 $(\mathbf{R}, \mathbf{t})$ （含尺度歧义）。

2.3 三角化与 Bundle Adjustment

已知相机投影矩阵 $\mathbf{P}_1, \mathbf{P}_2$ 与匹配像素 $\mathbf{p}_1, \mathbf{p}_2$ ，可通过线性 DLT 或中点法计算 3D 点 $\mathbf{X}$ ，这一过程称为三角化：

$$\mathbf{p}_i \propto \mathbf{P}_i \mathbf{X}, \quad i = 1, 2. \quad (3)$$

对整个场景而言，带噪声的观测会导致误差累积，需要通过捆绑调整（Bundle Adjustment, BA）进行全局非线性优化。设 $\pi(\cdot)$ 为投影函数（含内参和畸变）， $\mathbf{p}_{ij}$ 为第 i 台相机观测到的第 j 个点的像素位置，则 BA 的典型目标函数为：

$$\min_{\{\mathbf{R}_i, \mathbf{t}_i\}, \{\mathbf{X}_j\}} \sum_{i,j} \rho \left(\left\| \pi(\mathbf{R}_i \mathbf{X}_j + \mathbf{t}_i) - \mathbf{p}_{ij} \right\|^2 \right), \quad (4)$$

其中 $\rho(\cdot)$ 为鲁棒核函数（如 Huber），以降低误匹配对优化的影响。COLMAP 采用增量式 SfM：从少量视图初始化，逐步加入新视图并在每一步执行局部或全局 BA。

2.4 多视图立体 (MVS) 与稠密重建

在 SfM 获得准确相机位姿后，多视图立体 (MVS) 进一步估计每个像素的深度，从而形成稠密点云。COLMAP 中典型流程为：

1. 去畸变与统一成像模型：将图像统一到理想针孔模型，方便后续几何推理；
2. PatchMatch Stereo：为每个像素估计局部平面（由深度 d 与法向 $\mathbf{n}$ 描述），通过随机初始化、邻域传播与随机扰动迭代优化，在光度一致性损失（如 NCC 或绝对差）下收敛；
3. 多视图深度融合：对各图像的深度图进行几何一致性检测，将多视图一致的像素融合为 3D 点，得到稠密点云。

在本仓库面向 NeRF / Nerfstudio 的实践中，稀疏层的相机位姿已经足够驱动后续辐射场训练，稠密 MVS 是可选的增强步骤。

3 辐射场层：NeRF 与体渲染

3.1 连续辐射场表示

NeRF 将场景表示为一个连续的辐射场函数

$$f : (\mathbf{x}, \mathbf{d}) \mapsto (\mathbf{c}, \sigma), \quad (5)$$

其中 $\mathbf{x} \in \mathbb{R}^3$ 为 3D 空间点， $\mathbf{d} \in \mathbb{S}^2$ 为视线方向， $\mathbf{c} \in \mathbb{R}^3$ 为 RGB 颜色， $\sigma \in \mathbb{R}_{\geq 0}$ 为体密度。在原始 NeRF 中， f 由一个多层感知机 (MLP) 拟合，输入为对 $\mathbf{x}, \mathbf{d}$ 做位置编码 (positional encoding) 后的高维特征：

$$\gamma_L(x) = \left(\sin(2^0 \pi x), \cos(2^0 \pi x), \dots, \sin(2^{L-1} \pi x), \cos(2^{L-1} \pi x) \right), \quad (6)$$

对每个坐标维度独立编码后再拼接。本仓库的语义 NeRF 模型也采用了类似的正余弦位置编码结构。

3.2 体渲染积分与离散近似

给定一条射线

$$\mathbf{r}(t) = \mathbf{o} + t\mathbf{d}, \quad t \in [t_n, t_f], \quad (7)$$

其中 $\mathbf{o}$ 为相机中心， $\mathbf{d}$ 为单位方向向量，NeRF 定义该射线对应像素颜色的体渲染积分为：

$$C(\mathbf{r}) = \int_{t_n}^{t_f} T(t) \sigma(\mathbf{r}(t)) \mathbf{c}(\mathbf{r}(t), \mathbf{d}) dt, \quad T(t) = \exp \left(- \int_{t_n}^t \sigma(\mathbf{r}(s)) ds \right). \quad (8)$$

实际实现中，将积分离散化为若干采样点 $\{t_i\}$ ，得到近似：

$$\hat{C}(\mathbf{r}) = \sum_i T_i (1 - \exp(-\sigma_i \delta_i)) \mathbf{c}_i, \quad T_i = \exp\left(-\sum_{j<i} \sigma_j \delta_j\right), \quad (9)$$

其中 $\delta_i = t_{i+1} - t_i$ 为相邻采样点间距。这一形式既保持了可微性，也较好逼近了体积渲染物理过程。

3.3 训练目标与变体

在监督训练设置下，给定一组多视角图像与相机位姿，对每条射线 $\mathbf{r}$ ，计算预测颜色 $\hat{C}(\mathbf{r})$ ，与真实像素颜色 $\mathbf{C}^*(\mathbf{r})$ 做损失：

$$\mathcal{L}_{\text{RGB}} = \frac{1}{N} \sum_{\mathbf{r}} \|\hat{C}(\mathbf{r}) - \mathbf{C}^*(\mathbf{r})\|_2^2 \quad \text{或更一般的感知损失}. \quad (10)$$

Nerfstudio 中的 `nerfacto` 等变体在以下方面做了大量工程优化：

- 使用多分辨率哈希网格等高效编码替代纯 MLP；
- 采用分层/重要性采样，提高采样点利用率；
- 加入外观编码、曝光校正等，以增强真实感与泛化能力。

尽管具体结构各异，它们在数学上仍服从“连续场 + 体渲染 + 可微优化”这一统一范式。

4 显式高效表示：3D Gaussian Splatting 与 4D 扩展

4.1 3D 高斯表示与参数化

3D Gaussian Splatting (3DGS) 使用一组带属性的三维高斯来显式表示场景。对单个高斯，可写为

$$\mathcal{G}(\mathbf{x}) = \alpha \cdot \exp\left(-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1}(\mathbf{x} - \boldsymbol{\mu})\right), \quad (11)$$

其中 $\boldsymbol{\mu} \in \mathbb{R}^3$ 为中心， $\boldsymbol{\Sigma} \in \mathbb{R}^{3 \times 3}$ 为正定协方差矩阵， α 为不透明度或密度相关系数，颜色可由 RGB 或球谐系数参数化。

为了保证 $\boldsymbol{\Sigma}$ 正定，实践中常采用

$$\boldsymbol{\Sigma} = \mathbf{R} \mathbf{S} \mathbf{S}^\top \mathbf{R}^\top, \quad (12)$$

其中 $\mathbf{R} \in SO(3)$ 为旋转矩阵， $\mathbf{S} = \text{diag}(s_x, s_y, s_z)$ 为尺度矩阵。3DGS 的优化过程即是在多视角图像监督下对 $(\boldsymbol{\mu}, \mathbf{R}, \mathbf{S}, \alpha, \text{color})$ 等参数做梯度更新。

4.2 Splatting 与可微渲染

在渲染时，首先将三维高斯按当前相机位姿投影到二维像素平面，得到 2D 高斯（中心与协方差经过线性变换），再按照深度从远至近排序，对每个像素做 alpha blending：

$$\mathbf{C}_{\text{out}} = \sum_k \tilde{\alpha}_k \left(\prod_{j < k} (1 - \tilde{\alpha}_j) \right) \mathbf{c}_k, \quad (13)$$

其中 $\tilde{\alpha}_k$ 为第 k 个高斯在该像素处的透明度权重， $\mathbf{c}_k$ 为其颜色。这一过程是可微的，可直接用反向传播优化高斯参数。

与 NeRF 相比，3DGS 在保持较高重建质量的同时，大幅提高了渲染速度与交互效率，更适合实时查看、编辑与下游任务。

4.3 4DGS 与动态场景

4D Gaussian Splatting (4DGS) 在 3DGS 的基础上将时间或隐空间纳入参数，例如令高斯中心或颜色为时间的函数：

$$\boldsymbol{\mu}(t), \quad \boldsymbol{\Sigma}(t), \quad \mathbf{c}(t), \quad (14)$$

从而表示动态场景或动作序列。在世界模型语境下，4DGS 扮演了“状态随时间演化”的显式表征角色，有利于对时空一致性的建模与推理。

5 语义层与世界记忆接口

5.1 2D 语义分割与像素级监督

语义层的第一步通常是对每张输入图像做 2D 语义分割。设某张图像尺寸为 $H \times W$ ，类别数为 K ，语义分割网络输出每个像素的 logits：

$$\mathbf{z}_{uv} \in \mathbb{R}^K, \quad (u, v) \in \{1, \dots, W\} \times \{1, \dots, H\}. \quad (15)$$

经过 softmax 得到类别概率

$$p(y_{uv} = k) = \frac{\exp(z_{uv}^{(k)})}{\sum_{k'} \exp(z_{uv}^{(k')})}, \quad (16)$$

训练时使用交叉熵损失：

$$\mathcal{L}_{\text{seg}} = -\frac{1}{HW} \sum_{u,v} \log p(y_{uv}^*), \quad (17)$$

其中 y_{uv}^* 为标注的真值类别。

本仓库的 `scripts/run_semantic_labeling.py` 负责对 Nerfstudio 预处理后的图像生成像素级 label map，并可选汇总为每张图的类别统计等元数据。

5.2 3D 语义融合：从图像到点云

在已知 COLMAP 稀疏点云与其多视图观测的前提下，可将 2D 语义标签投票到 3D 点上，得到“带语义的点云”。设某个 3D 点 $\mathbf{X}$ 在若干图像中的投影像素为 $\{(u_i, v_i)\}$ ，对应的 2D 语义标签为 $\{y_i\}$ ，则可定义该点的 3D 语义标签为

$$\hat{y}(\mathbf{X}) = \arg \max_k \sum_i w_i \mathbf{1}[y_i = k], \quad (18)$$

其中 $\{w_i\}$ 为基于视角、深度或置信度的权重。

在本仓库中，`semantic_scene.json` 记录了这样的 3D 语义点信息，并提供了按类别、按 3D 区域、按查询点检索的接口。

5.3 语义 NeRF 与语义 3DGS

在此基础上，可以在辐射场与 3DGS 层面进一步引入语义监督。

语义 NeRF： 对每个采样点，NeRF 模型除了输出 $(\mathbf{c}, \sigma)$ 外，还预测语义 logits $\mathbf{s} \in \mathbb{R}^K$ 。在体渲染过程中，同时对 RGB 与语义进行加权积分：

$$\hat{\mathbf{C}}(\mathbf{r}) = \sum_i w_i \mathbf{c}_i, \quad (19)$$

$$\hat{\mathbf{s}}(\mathbf{r}) = \sum_i w_i \mathbf{s}_i, \quad (20)$$

其中 w_i 为与密度相关的体渲染权重。对每条射线的语义标签 y^* 使用交叉熵损失：

$$\mathcal{L}_{\text{sem-NeRF}} = -\frac{1}{N} \sum_r \log \frac{\exp(\hat{s}_{y^*}(\mathbf{r}))}{\sum_k \exp(\hat{s}_k(\mathbf{r}))}. \quad (21)$$

总损失为 RGB 与语义损失的加权和。本仓库的 `src/semantic_nerf` 模块实现了一个轻量级语义 NeRF。

语义 3DGS： 类似地，可在每个高斯上附加语义 logits，渲染语义图并用 2D 标签监督。由于几何与颜色已由基础 3DGS 学得，语义头的训练可以在冻结几何与 RGB 的条件下进行，从而提高优化稳定性。

6 统一静态场景状态与世界模型视角

为了在世界模型实验中复用同一真实场景，本仓库通过静态场景状态 (*Scene State*) 将多种表示统一到一个 JSON 描述中，例如 `mipnerf360/db/playroom/world_state.playroom.json`。其核心思想包括：

- 统一的场景 ID、根目录与世界坐标系说明；

- 集中记录 COLMAP、Nerfstudio/NeRF、3DGS 与 semantics 各自的数据与模型路径;
- 通过 SceneState 与 SemanticScene 等数据结构, 提供按类别、按 3D 区域、按点的可查询接口。

从更宏观的角度看, 几何层保证物理一致性, 辐射场层保证真实感, 显式层保证效率与可编辑性, 语义层与 *Scene State* 则将这些表示组织成统一的世界记忆单元。这正是面向世界模型的 3D/360 重建技术路径的核心理念。

7 结语

本文以 3D_Reconstruction_ing 仓库为背景, 围绕几何、辐射场、显式高斯表示与语义层, 梳理了从传统三维重建走向世界模型的关键数学原理与算法框架。配合工程实践文档 (另见配套的工程实现教程 L^AT_EX 文档), 读者可以一方面从理论上理解各层组件的角色与联系, 另一方面在真实数据集 (如 Mip-NeRF 360) 上动手打通整条 Pipeline。