

从三维重建到世界模型的技术路径综述

几何、辐射场与显式表示

3D_Reconstruction_ing 项目笔记

2026 年 7 月 6 日

摘要

本文围绕“从三维重建到世界模型”的技术栈，综述传统几何重建 (SfM/MVS)、辐射场方法 (NeRF 系列) 与显式高效表示 (3D Gaussian Splatting/4DGS) 在 3D/360 场景建模中的核心思想、关键公式与工程要点。与只关注离线重建不同，世界模型更强调可查询、可渲染、可编辑与可增量更新的场景表示：几何层提供物理一致性与位姿基座，辐射场层提供连续外观建模，显式表示层提供实时渲染与交互效率，语义层与统一场景状态 (Scene State) 则将多种表征组织为可复用的“世界记忆”。本文以开源工具链 COLMAP[1, 2] 与 Nerfstudio[6] 为典型工程载体，结合 Mip-NeRF 360[5]、3D Gaussian Splatting[7]、4D Gaussian Splatting[8] 等代表性工作，给出面向实践的选型与评估视角。

目录

1 引言：三维重建与世界模型	3
2 几何层：多视图几何与 COLMAP	4
2.1 COLMAP 的整体流水线（从图像到稀疏/稠密模型）	4
2.2 针孔相机模型、畸变与坐标系约定	5
2.3 局部特征、匹配与两视图几何验证（SfM 的“数据入口”）	5
2.4 对极几何、本质矩阵与相对位姿	5
2.5 三角化、轨迹（tracks）与增量式建图（Incremental SfM）	6
2.6 Bundle Adjustment：把噪声、外点与漂移压回去	6
2.7 多视图立体（MVS）：从位姿到稠密深度	6
3 360 全景重建的特化问题与工程坑	7
3.1 相机模型与投影：等矩形、鱼眼与多相机 Rig	7
3.2 弱视差与纯旋转：深度退化与尺度不稳定	8

目录	2
3.3 回环一致性：长序列漂移与闭环约束	8
3.4 天空、反光与透明：不可重建区域与可见性噪声	8
3.5 一份可执行的 360 数据处理 Checklist	9
4 辐射场层：NeRF 与体渲染	9
4.1 连续辐射场表示	9
4.2 体渲染积分与离散近似	10
4.3 训练目标与变体	10
4.4 NeRF 论文精读：核心内容、公式与创新点	10
4.4.1 核心概述	11
4.4.2 核心场景表示：5D 神经辐射场	11
4.4.3 可微体渲染管线	11
4.4.4 核心优化技术	11
4.4.5 核心公式详解	12
4.4.6 创新点分析（与本综述的关联）	13
4.4.7 小结	13
5 显式高效表示：3D Gaussian Splatting 与 4D 扩展	14
5.1 论文核心内容与动机	14
5.2 方法整体框架	14
5.3 关键模块补充：自适应密度控制与瓦片光栅化	14
5.4 3D 高斯表示与参数化	15
5.5 Splatting 与可微渲染	15
5.6 创新点小结	16
5.7 4DGS 与动态场景	16
5.7.1 规范高斯 + 时空形变场	16
5.7.2 HexPlane 多平面时空编码	16
5.7.3 渲染与损失	17
5.7.4 两阶段优化策略	17
5.7.5 要点小结	17
6 语义层与世界记忆接口	17
6.1 2D 语义分割与像素级监督	17
6.2 3D 语义融合：从图像到点云	18
6.3 语义 NeRF 与语义 3DGS	18
6.4 相机可控视频生成与 3D 几何记忆：WorldStereo[11]	19
6.4.1 研究背景与挑战	19
6.4.2 整体框架：Multi-Bi-Mem 生成与重建闭环	19

1 引言：三维重建与世界模型	3
6.4.3 关键模块与公式	20
6.4.4 创新点与技术价值	21
6.5 演化式全景世界生成与显式 3D 记忆：EvoWorld[10]	21
6.5.1 问题设定与闭环流程	21
6.5.2 关键公式：记忆重投影、扩散采样与记忆更新	22
6.5.3 全景球面与位姿嵌入：球面 Plücker 表达	22
6.5.4 创新点与价值总结	23
7 统一静态场景状态与世界模型视角	23
8 评估指标体系：几何、渲染与世界模型导向	24
8.1 几何与位姿指标 (Geometry / Pose)	24
8.2 新视图合成指标 (Rendering / NVS)	24
8.3 效率与资源 (Efficiency)	25
8.4 世界模型导向指标 (World-Model-Oriented)	25
8.5 指标与产物对照表 (建议直接贴到实验记录模板)	26
9 结语	26

1 引言：三维重建与世界模型

三维与全景重建 (3D / 360 Reconstruction) 关注从多视角图像或视频中恢复世界的几何结构与全景语义。在世界模型视角下，我们期望的不只是离线重建一个静态场景，而是构建一个可查询、可渲染、可推理的空间表示，用于支撑导航、编辑、理解与生成等多种下游任务。

从工程落地角度，本文也关注一条可复现的工具链：以 COLMAP 得到相机位姿与稀疏结构，再在 Nerfstudio 上训练辐射场模型，最后可切换到 3DGS/4DGS 以获得更高的渲染效率。

该技术路径可以概括为：

围绕 Mip-NeRF 360[5] 等真实世界数据，搭建从 COLMAP[1, 2] $\rightarrow$ Nerfstudio[6] $\rightarrow$ 3DGS[7] / 4DGS[8] 的实践管线，为面向世界模型的 3D/360 场景表示打基础。

从技术栈角度，核心可拆解为三层：

1. 几何层 (Geometry / SfM / MVS)：

估计相机位姿与稀疏/稠密点云，保证几何与物理一致性。

2. 辐射场层 (Radiance Field / NeRF)：

学习连续体积场函数 $f(\mathbf{x}, \mathbf{d})$ ，从任意视角渲染高质量图像。

3. 显式高效表示层 (3DGS / 4DGS 等):

用高斯云等显式结构替代纯 MLP 体渲染，在保证质量的前提下提升渲染效率与可编辑性。

在此之上，再叠加语义层与统一的场景状态 (Scene State)，构成可查询、可组合的世界记忆。

2 几何层：多视图几何与 COLMAP

几何层解决的问题可以概括为：给定一组重叠视角的图像（或视频帧），恢复 (i) 每张图像的相机参数（内参/畸变/外参）与 (ii) 场景中可重复观测的 3D 结构点。这对应经典的结构从运动 (Structure-from-Motion, SfM) 与多视图立体 (Multi-View Stereo, MVS)。COLMAP[1, 2] 将这两部分做成了工程化的可复现流水线：特征提取/匹配 → 两视图几何验证 → 增量式建图 (SfM) → (可选) 稠密深度估计与融合 (MVS)。

2.1 COLMAP 的整体流水线（从图像到稀疏/稠密模型）

为了把“论文里的几何”落到可运行的系统上，理解 COLMAP 的模块划分很重要。一个典型的 COLMAP 流程包含：

1. **特征提取 (Feature Extraction)**: 对每张图像提取局部特征（默认 SIFT），得到关键点位置与描述子；
2. **特征匹配 (Feature Matching)**: 在图像对之间做描述子近邻匹配，并使用比值检验 (ratio test) 等策略过滤；
3. **几何验证 (Geometric Verification)**: 对每个候选图像对，用 RANSAC 估计基础矩阵/本质矩阵/单应矩阵，剔除外点，得到可靠的内点匹配；
4. **增量式 SfM (Incremental Mapping)**: 从一个“种子”两视图初始化，逐步加入新图像：新图像位姿用 PnP 求解，新的 3D 点通过三角化生成，并在每一步做 (局部/全局) Bundle Adjustment；
5. **(可选) 稠密重建 (Dense MVS)**: 对每张图像估计深度图 (PatchMatch Stereo)，再做多视图一致性检查与深度融合，得到稠密点云，之后可进一步网格化与贴图。

实践上，若目标是 NeRF / 3DGS 等“需要相机位姿即可训练”的方法，SfM 的稀疏位姿 + 稀疏点云通常已经足够；MVS 主要用于得到更稠密的几何先验（例如深度监督、掩码/可见性推断、或高质量网格输出）。

2.2 针孔相机模型、畸变与坐标系约定

在多视图几何中，针孔相机模型将 3D 点 $\mathbf{X} = (X, Y, Z)^\top$ 映射到图像平面像素 $\mathbf{p} = (u, v)^\top$:

$$\lambda \begin{bmatrix} u \\ v \\ 1 \end{bmatrix} = \mathbf{K} \begin{bmatrix} \mathbf{R} & \mathbf{t} \\ \mathbf{0}^\top & 1 \end{bmatrix} \begin{bmatrix} X \\ Y \\ Z \\ 1 \end{bmatrix}, \quad \mathbf{K} = \begin{bmatrix} f_x & 0 & c_x \\ 0 & f_y & c_y \\ 0 & 0 & 1 \end{bmatrix}. \quad (1)$$

其中 $\mathbf{R} \in SO(3)$ 、 $\mathbf{t} \in \mathbb{R}^3$ 为外参， $\mathbf{K}$ 为内参， λ 为尺度因子。

真实相机往往存在径向/切向畸变。以常见的 Brown–Conrady (OpenCV) 模型为例，令归一化坐标为 (x, y) ，半径平方 $r^2 = x^2 + y^2$ ，径向畸变系数 (k_1, k_2, k_3) 、切向畸变系数 (p_1, p_2) ，则畸变后坐标 (x_d, y_d) 可写为：

$$x_d = x(1 + k_1 r^2 + k_2 r^4 + k_3 r^6) + 2p_1 xy + p_2(r^2 + 2x^2), \quad (2)$$

$$y_d = y(1 + k_1 r^2 + k_2 r^4 + k_3 r^6) + p_1(r^2 + 2y^2) + 2p_2 xy. \quad (3)$$

COLMAP 支持多种相机模型（针孔、简单针孔、OpenCV、鱼眼等），并在 BA 中把内参/畸变作为可优化变量之一。

2.3 局部特征、匹配与两视图几何验证 (SfM 的“数据入口”)

SfM 的质量很大程度取决于匹配质量。COLMAP 默认使用 SIFT 特征：关键点提供尺度/旋转不变的局部位置，描述子在高维空间中做近邻检索得到匹配对。匹配阶段常见的两道“工程护栏”是：(1) Lowe 比值检验过滤歧义匹配；(2) 互为最近邻 (mutual check) 减少单向误匹配。

但光靠描述子相似度仍会产生大量外点，所以需要几何验证。对每个图像对，COLMAP 会在 RANSAC 框架下拟合基础矩阵 $\mathbf{F}$ （一般场景）或单应矩阵 $\mathbf{H}$ （近平面/纯旋转），并用重投影误差判定内点。这一步把“看起来像”变成“几何上说得通”，决定了后续三角化与 BA 的上限。

2.4 对极几何、本质矩阵与相对位姿

在两视图情形下，空间点 $\mathbf{X}$ 在两个相机中的像素分别为 $\mathbf{p}_1, \mathbf{p}_2$ （齐次坐标），则存在本质矩阵 $\mathbf{E}$ 与基础矩阵 $\mathbf{F}$ 使得：

$$\mathbf{p}_2^\top \mathbf{F} \mathbf{p}_1 = 0, \quad \mathbf{F} = \mathbf{K}_2^{-\top} \mathbf{E} \mathbf{K}_1^{-1}, \quad \mathbf{E} = [\mathbf{t}]_{\times} \mathbf{R}, \quad (4)$$

其中 $[\mathbf{t}]_{\times}$ 为由平移向量 $\mathbf{t}$ 构造的反对称矩阵。给定 $\mathbf{E}$ 的 SVD 分解可得到候选的 $(\mathbf{R}, \mathbf{t})$ ，再通过 *cheirality*（点应落在两个相机前方）约束选取正确解。需要强调的是：单目两视图恢复的平移只有方向，整体尺度不可观 (scale ambiguity)，后续只能在“相似变换”（旋转/平移/尺度）意义下确定结构。

2.5 三角化、轨迹 (tracks) 与增量式建图 (Incremental SfM)

COLMAP 的增量式 SfM 可以用“不断把新视图并入当前 3D 地图”来理解：首先从一对视图初始化，三角化得到初始 3D 点集；然后对一个待加入的新图像：

1. **建立 2D-3D 对应**：通过匹配把新图像中的 2D 特征与已建图中的 3D 点关联；
2. **PnP 求解相机位姿**：在 RANSAC 中求解使 2D-3D 重投影误差最小的位姿；
3. **新增点三角化**：把新图像与已定位图像之间的内点匹配三角化生成新 3D 点；
4. **局部 BA**：对局部子图（新图像及其邻域）优化位姿与点，稳定并抑制漂移。

三角化可由线性 DLT 得到初值，再通过最小化重投影误差做非线性 refinement。设投影矩阵为 P_i ，观测像素为 p_i ，则理想关系为：

$$p_i \propto P_i X. \quad (5)$$

在实现里，COLMAP 会维护“轨迹” (tracks)：同一真实 3D 点在多张图像中的一组 2D 观测，它是 BA 的基本数据结构。

2.6 Bundle Adjustment：把噪声、外点与漂移压回去

对整个场景而言，观测噪声与少量误匹配会导致误差累积，需要通过捆绑调整 (Bundle Adjustment, BA) 进行全局非线性优化。设 $\pi(\cdot)$ 为投影函数（含内参与畸变）， p_{ij} 为第 i 台相机观测到的第 j 个点的像素位置，则 BA 的典型目标函数为：

$$\min_{\{R_i, t_i, \theta_i\}, \{X_j\}} \sum_{i,j} \rho\left(\left\|\pi(R_i X_j + t_i; \theta_i) - p_{ij}\right\|^2\right), \quad (6)$$

其中 θ_i 表示该相机的内参与畸变参数， $\rho(\cdot)$ 为鲁棒核函数（如 Huber/Cauchy），以降低外点影响。该问题属于大规模稀疏非线性最小二乘，通常用 Gauss-Newton / Levenberg-Marquardt 求解；由于相机变量与点变量呈典型的“块稀疏”结构，工程上常用 Schur Complement 把点变量消元，显著加速求解。COLMAP 在增量式过程中穿插局部 BA，并在关键阶段执行全局 BA 以提高一致性。

2.7 多视图立体 (MVS)：从位姿到稠密深度

在 SfM 获得相机位姿后，多视图立体 (MVS) 进一步估计每个像素的深度，从而形成稠密点云。COLMAP 的稠密重建常见步骤为：

1. **去畸变与统一成像模型**：将图像统一到理想针孔或指定模型，方便后续几何推理；

2. **PatchMatch Stereo**: 为每个像素估计局部平面 (由深度 d 与法向 $\mathbf{n}$ 描述), 通过随机初始化、邻域传播与随机扰动迭代优化, 在光度一致性损失下收敛。光度一致性可用归一化互相关 (NCC) 等度量, 典型形式为 $\mathcal{L}_{photo} = 1 - \text{NCC}(\text{patch}_r, \text{patch}_s)$;
3. **几何一致性与融合**: 把不同视图的深度通过已知位姿互相重投影, 对通过一致性阈值的像素进行融合, 得到稠密点云。

在面向 NeRF / Nerfstudio / 3DGS 的实践中, 稀疏层的相机位姿已经足够驱动后续辐射场或显式表示的训练, 稠密 MVS 可作为增强步骤: 例如用深度作为监督、用稠密点云初始化高斯或网格、或为全景/360 场景提供更稳定的遮挡与可见性估计。

3 360 全景重建的特化问题与工程坑

相比常规透视相机的多视图重建, 360 全景 (等矩形/鱼眼/多相机拼接) 数据在成像模型、视差结构与可用特征分布上都更“奇怪”, 因此也更容易踩坑。本节从工程角度总结若干在 3D/360 管线中高频出现的问题, 并给出可操作的规避策略。

3.1 相机模型与投影: 等矩形、鱼眼与多相机 Rig

等矩形 (Equirectangular) 投影。 将单位球面方向向量 $\mathbf{d} = (d_x, d_y, d_z)^\top$ 映射到经纬角:

$$\phi = \text{atan2}(d_x, d_z), \quad \theta = \arcsin(d_y), \quad (7)$$

其中 $\phi \in [-\pi, \pi)$ 为方位角, $\theta \in [-\frac{\pi}{2}, \frac{\pi}{2}]$ 为俯仰角。对应到像素 (宽 W 、高 H) 可写为

$$u = \left(\frac{\phi}{2\pi} + \frac{1}{2}\right)W, \quad v = \left(\frac{1}{2} - \frac{\theta}{\pi}\right)H. \quad (8)$$

等矩形图像在极区面积被强烈拉伸, 这会导致: 特征尺度畸变、匹配分布不均、以及渲染评估指标的面积权重偏差 (见第 8 节)。

鱼眼与宽视场模型。 对真实 360 相机 (鱼眼/双鱼眼/多相机拼接), 用针孔 + 低阶径向畸变往往不够, 建议优先使用鱼眼/通用模型 (如 Kannala-Brandt 多项式模型) 进行标定与优化 [3]。在 SfM/MVS 中, 相机模型选错会导致位姿被“畸变误差”吸收, 从而出现结构弯曲、尺度漂移等隐性问题。

工程落地建议。 若工具链对全景模型支持有限, 一个实用折中是: 将等矩形全景切分成若干视角固定的透视视图 (cubemap 或多方向 pinhole views), 在透视域做 SfM/MVS, 再把结果映射回全景坐标系; 这能显著提升特征匹配的稳定性, 但需要注意不同视图之间的重叠与时间同步。

3.2 弱视差与纯旋转：深度退化与尺度不稳定

全景视频经常出现“几乎原地转圈”的采集模式：角度变化很大，但平移基线很小。这会导致典型退化：

- **SfM 三角化退化**：平移不足使三角化条件数变差，点云更稀疏且噪声更大；
- **尺度与远景深度不稳定**：远处结构基本无视差，深度更容易被外观解释“吞掉”；
- **NeRF/3DGS 的几何漂移**：若位姿存在小系统误差，体渲染/高斯优化会把误差转移到密度/几何上，造成“看起来对但几何不对”。

应对策略。 最有效的办法不是调参，而是采集与抽帧策略：

1. 选取具有足够平移基线的片段（比如沿走廊/环绕物体走一圈），避免长时间纯旋转；
2. 抽帧时同时约束角度差与平移差，不要只按时间间隔抽帧；
3. 对弱纹理/远景区域，引入深度先验（MVS 深度、单目深度、或稀疏点约束）作为正则项，降低漂移风险。

3.3 回环一致性：长序列漂移与闭环约束

360 场景常用于“长航迹/回环探索”，而增量式 SfM 的漂移会在回到起点时集中爆发：同一位置的结构无法对齐，进而影响后续 NeRF/3DGS 的全局一致性。实践中可从两条线解决：

- **几何侧**：尽量在 SfM 阶段就强化闭环（更强的回环检索/匹配、关键帧选择、全局 BA 或位姿图优化）；
- **生成/世界模型侧**：利用显式 3D 记忆对生成或重建进行几何约束，减少长时序漂移累积（例如 EvoWorld[10]、WorldStereo[11] 一类“重建-生成闭环”范式）。

3.4 天空、反光与透明：不可重建区域与可见性噪声

天空、镜面/玻璃、强反光和动态物体会同时破坏特征匹配与光度一致性假设：

- **SfM/MVS**：这些区域的匹配不稳定，容易引入错误约束；
- **NeRF**：模型可能把“不可解释的外观”吸收到密度里，产生漂浮伪几何；
- **3DGS**：会出现漂浮高斯、透明体积被误建模为不透明等问题。

工程建议。

1. 用 2D 分割/掩码把天空、镜面、动态物体在 SfM/MVS 阶段降低权重或剔除；
2. 对天空/远景可单独建模为“无限远背景”（例如单独的 skybox/背景层），不要强行三角化；
3. 在辐射场或 3DGS 优化中加入鲁棒损失、深度/法向正则，或使用可见性/遮挡一致性约束来抑制漂浮伪几何。

3.5 一份可执行的 360 数据处理 Checklist

- **相机模型**：确认等矩形/鱼眼/拼接方式；优先使用与硬件匹配的畸变模型；
- **抽帧策略**：同时覆盖角度与平移基线；避免长时间纯旋转；
- **掩码策略**：天空/反光/动态物体尽量早处理（SfM/MVS 前）；
- **回环**：长序列优先考虑回环增强（检索、匹配、全局 BA）；
- **验收**：先验收位姿与稀疏点云质量，再进入 NeRF/3DGS（否则后面都是“带病训练”）。

4 辐射场层：NeRF 与体渲染

4.1 连续辐射场表示

NeRF 将场景表示为一个连续的辐射场函数

$$f : (\mathbf{x}, \mathbf{d}) \mapsto (\mathbf{c}, \sigma), \quad (9)$$

其中 $\mathbf{x} \in \mathbb{R}^3$ 为 3D 空间点， $\mathbf{d} \in \mathbb{S}^2$ 为视线方向， $\mathbf{c} \in \mathbb{R}^3$ 为 RGB 颜色， $\sigma \in \mathbb{R}_{\geq 0}$ 为体密度。在原始 NeRF 中， f 由一个多层感知机（MLP）拟合，输入为对 $\mathbf{x}, \mathbf{d}$ 做位置编码（positional encoding）后的高维特征：

$$\gamma_L(x) = \left(\sin(2^0 \pi x), \cos(2^0 \pi x), \dots, \sin(2^{L-1} \pi x), \cos(2^{L-1} \pi x) \right), \quad (10)$$

对每个坐标维度独立编码后再拼接。在一些工程实现中，语义 NeRF 也会沿用类似的正余弦位置编码结构。

4.2 体渲染积分与离散近似

给定一条射线

$$\mathbf{r}(t) = \mathbf{o} + t\mathbf{d}, \quad t \in [t_n, t_f], \quad (11)$$

其中 $\mathbf{o}$ 为相机中心， $\mathbf{d}$ 为单位方向向量，NeRF 定义该射线对应像素颜色的体渲染积分为：

$$C(\mathbf{r}) = \int_{t_n}^{t_f} T(t) \sigma(\mathbf{r}(t)) \mathbf{c}(\mathbf{r}(t), \mathbf{d}) dt, \quad T(t) = \exp\left(-\int_{t_n}^t \sigma(\mathbf{r}(s)) ds\right). \quad (12)$$

实际实现中，将积分离散化为若干采样点 $\{t_i\}$ ，得到近似：

$$\hat{C}(\mathbf{r}) = \sum_i T_i (1 - \exp(-\sigma_i \delta_i)) \mathbf{c}_i, \quad T_i = \exp\left(-\sum_{j < i} \sigma_j \delta_j\right), \quad (13)$$

其中 $\delta_i = t_{i+1} - t_i$ 为相邻采样点间距。这一形式既保持了可微性，也较好逼近了体积渲染物理过程。

4.3 训练目标与变体

在监督训练设置下，给定一组多视角图像与相机位姿，对每条射线 $\mathbf{r}$ ，计算预测颜色 $\hat{C}(\mathbf{r})$ ，与真实像素颜色 $C^*(\mathbf{r})$ 做损失：

$$\mathcal{L}_{\text{RGB}} = \frac{1}{N} \sum_{\mathbf{r}} \|\hat{C}(\mathbf{r}) - C^*(\mathbf{r})\|_2^2 \quad \text{或更一般的感知损失}. \quad (14)$$

Nerfstudio 中的 `nerfacto` 等变体在以下方面做了大量工程优化：

- 使用多分辨率哈希网格等高效编码替代纯 MLP；
- 采用分层/重要性采样，提高采样点利用率；
- 加入外观编码、曝光校正等，以增强真实感与泛化能力。

尽管具体结构各异，它们在数学上仍服从“连续场 + 体渲染 + 可微优化”这一统一范式。

4.4 NeRF 论文精读：核心内容、公式与创新点

下面补充对 NeRF 原论文 (*NeRF: Representing Scenes as Neural Radiance Fields for View Synthesis*) 的更细化梳理。该部分与上文“连续场 + 体渲染 + 可微优化”的主线保持一致，但把关键公式、采样策略与创新点讲清楚，便于后续对比 Nerfstudio/`nerfacto`、Mip-NeRF 360、3DGS 等路线的取舍。

关键词：神经辐射场；新视图合成；可微体渲染；位置编码；层级采样

4.4.1 核心概述

NeRF 的核心任务是解决稀疏输入视图下的照片级新视图合成。其核心思路是：将静态场景建模为一个连续的 5D 向量值函数，结合经典可微体渲染，通过渲染结果与真实图像的像素误差反向传播，端到端优化场景表示，最终实现任意新视角的高保真渲染。

相较于离散场景表示（体素、网格等），NeRF 用隐式函数同时编码场景几何与视角相关外观，避免“分辨率提升 $\Rightarrow$ 存储/计算爆炸”的瓶颈，从而在复杂真实场景上获得更高的渲染质量。

4.4.2 核心场景表示：5D 神经辐射场

NeRF 将场景建模为连续的 5D 神经辐射场函数：

$$F_{\Theta} : (\mathbf{x}, \mathbf{d}) \rightarrow (\mathbf{c}, \sigma), \quad (15)$$

其中：

- 输入：3D 空间坐标 $\mathbf{x} = (x, y, z)$ ，以及 2D 视角方向对应的 3D 单位向量 $\mathbf{d}$ （等价于球坐标 (θ, ϕ) 的表示）；
- 输出：该空间点的体密度 σ （仅由 $\mathbf{x}$ 决定，以保证多视角几何一致性），以及视角相关的 RGB 颜色 $\mathbf{c} = (r, g, b)$ （由 $\mathbf{x}$ 与 $\mathbf{d}$ 共同决定，用于建模非朗伯效应）；
- 网络参数： Θ 为多层感知机（MLP）的权重。

原始 NeRF 的 MLP 结构强调“几何（密度）与外观（颜色）”的解耦：先用位置编码后的 $\mathbf{x}$ 预测 σ 与中间特征，再将特征与位置编码后的 $\mathbf{d}$ 拼接以预测颜色 $\mathbf{c}$ 。这也是后来许多 NeRF 变体保留的设计范式。

4.4.3 可微体渲染管线

对虚拟相机每个像素发射一条光线，计算光线穿过场景时沿途所有点的颜色与密度的加权累积，得到该像素颜色。相机光线方程为：

$$\mathbf{r}(t) = \mathbf{o} + t\mathbf{d}, \quad t \in [t_n, t_f], \quad (16)$$

其中 $\mathbf{o}$ 为相机光心， $\mathbf{d}$ 为单位方向向量， $[t_n, t_f]$ 为近远裁剪平面对应的深度范围。

4.4.4 核心优化技术

位置编码 (Positional Encoding) 为缓解 MLP 的“频谱偏置”（更易拟合低频函数），NeRF 将低维坐标输入映射到高维的正余弦基上，使网络更容易表示高频细节。

层级体采样 (Hierarchical Volume Sampling) 采用“粗网络 + 细网络”两阶段: 粗网络先用较少采样点得到沿光线的权重分布 (近似 PDF), 细网络再进行重要性采样, 把更多采样预算集中到对最终颜色贡献大的区域 (通常是物体表面附近), 从而提高效率与质量。

4.4.5 核心公式详解

体渲染连续积分

$$C(\mathbf{r}) = \int_{t_n}^{t_f} T(t) \sigma(\mathbf{r}(t)) \mathbf{c}(\mathbf{r}(t), \mathbf{d}) dt, \quad (17)$$

其中透射率 (未被遮挡的概率)

$$T(t) = \exp \left(- \int_{t_n}^t \sigma(\mathbf{r}(s)) ds \right). \quad (18)$$

分层随机采样 将区间 $[t_n, t_f]$ 划分为 N 个等距小段, 并在每段内均匀随机采样:

$$t_i \sim \mathcal{U} \left[t_n + \frac{i-1}{N} (t_f - t_n), t_n + \frac{i}{N} (t_f - t_n) \right]. \quad (19)$$

该策略保证训练过程中查询的是“连续位置”, 并在实践中降低条纹伪影与过拟合到固定采样格点的风险。

离散体渲染求积 (Alpha 合成形式)

$$\hat{C}(\mathbf{r}) = \sum_{i=1}^N T_i (1 - \exp(-\sigma_i \delta_i)) \mathbf{c}_i, \quad (20)$$

其中 $\delta_i = t_{i+1} - t_i$, 并且

$$T_i = \exp \left(- \sum_{j=1}^{i-1} \sigma_j \delta_j \right). \quad (21)$$

该形式全程可微, 可将 2D 像素误差反向传播到 MLP 的参数 Θ 。

位置编码 对每个标量分量 p ($\mathbf{x}$ 或 $\mathbf{d}$ 的分量):

$$\gamma(p) = (\sin(2^0 \pi p), \cos(2^0 \pi p), \dots, \sin(2^{L-1} \pi p), \cos(2^{L-1} \pi p)). \quad (22)$$

原论文中空间坐标通常取 $L = 10$, 视角方向取 $L = 4$; 实践中也常根据场景尺度做归一化或坐标缩放。

层级采样权重 粗网络的离散渲染可写为

$$\hat{C}_c(\mathbf{r}) = \sum_{i=1}^{N_c} w_i \mathbf{c}_i, \quad (23)$$

其中权重

$$w_i = T_i (1 - \exp(-\sigma_i \delta_i)). \quad (24)$$

将 w_i 归一化得到分段常数 PDF, 通过逆变换采样抽取 N_f 个细采样点, 与粗采样点合并后输入细网络。

优化损失 粗、细网络同时监督:

$$\mathcal{L} = \sum_{\mathbf{r} \in \mathcal{R}} \left[\left\| \hat{C}_c(\mathbf{r}) - C(\mathbf{r}) \right\|_2^2 + \left\| \hat{C}_f(\mathbf{r}) - C(\mathbf{r}) \right\|_2^2 \right], \quad (25)$$

其中 $\mathcal{R}$ 为 batch 中的射线集合, $C(\mathbf{r})$ 为真实像素颜色。

4.4.6 创新点分析 (与本综述的关联)

- **5D 连续场景表示范式:** 用 MLP 参数化的连续函数同时表示几何 (密度) 与外观 (辐射度), 为后续“神经场景表示”打开了大门。
- **完全可微体渲染:** 不依赖深度/网格真值, 直接用 RGB 重投影误差端到端优化, 极大降低高质量重建门槛。
- **位置编码:** 显著提升高频细节拟合能力, 是 NeRF “不糊” 的关键之一, 也影响了后续哈希/多分辨率编码等加速路线的设计。
- **层级采样:** 把算力集中到“有效深度”, 与后续各种重要性采样/空洞跳过 (empty space skipping) 在思想上同源。
- **几何-外观解耦:** 密度仅依赖位置保证多视角一致性, 颜色依赖方向建模高光反射, 为真实感渲染提供必要自由度。

4.4.7 小结

NeRF 证明了“连续辐射场 + 可微体渲染”能在真实复杂场景上实现高保真新视图合成, 并直接推动了 Mip-NeRF 360、Instant-NGP、Nerfstudio 系列以及 3DGS/4DGS 等一整条技术谱系的发展。在工程落地时, NeRF 的主要痛点通常在训练与渲染成本; 这也正是本综述后续转向显式高效表示 (3DGS/4DGS) 的动机之一。

5 显式高效表示：3D Gaussian Splatting 与 4D 扩展

5.1 论文核心内容与动机

3D Gaussian Splatting (3DGS) [7] 直指传统 NeRF “质量与实时渲染难以兼得”的工程瓶颈：高质量 NeRF 系列通常依赖逐光线采样与体渲染积分，导致训练与渲染成本随分辨率显著增长；而更快的神经场表示方法虽然将训练压缩到分钟级，但在 1080p 等高分辨率下仍难稳定达到实时帧率，同时容易出现质量退化。3DGS 的基本策略是改用**显式、可微、点基**的辐射场表示：用一组带各向异性形状与视角相关颜色的三维高斯“覆盖”场景表面与外观，再用 GPU 友好的光栅化与有序 α 混合实现实时新视角渲染。

5.2 方法整体框架

输入为多视角静态图像、SfM 标定的相机参数，以及 SfM 稀疏点云初始化；输出为一组可优化的 3D 高斯参数（位置、形状、透明度与颜色/球谐系数），并支持实时渲染。整体流程可概括为：

1. **可微 3D 高斯场景表示**：以非结构化高斯集合替代 MLP 隐式场；
2. **带自适应密度控制的优化**：在优化过程中动态克隆/分裂/剔除高斯以提升表示能力；
3. **瓦片式快速可微光栅化器**：以瓦片裁剪与一次排序实现高效前向渲染与稳定反传。

5.3 关键模块补充：自适应密度控制与瓦片光栅化

自适应密度控制 (Density Control) 为在固定训练预算内兼顾细节与稳定性，3DGS 使用“优化中生长”的表示策略。在实践中常用的监督为像素级重建损失（例如 L1）与结构相似性项（例如 D-SSIM）加权：

$$\mathcal{L} = (1 - \lambda) \mathcal{L}_1 + \lambda \mathcal{L}_{D-SSIM}, \quad \lambda = 0.2. \quad (26)$$

每隔若干迭代会根据梯度与屏幕投影尺度对高斯执行**克隆**（细小且梯度大）、**分裂**（过大且需要更高频细节）与**剔除**（长期贡献低），从而把参数预算用在“真正重要”的区域。

瓦片式可微光栅化 (Tile-based Rasterization) 渲染时将屏幕划分为固定大小瓦片（如 16×16 ），对每个视角先做视锥裁剪，再按“瓦片 ID + 深度”在 GPU 上做一次全局排序，保证同一瓦片内从远到近的有序混合。前向采用从前到后（front-to-back）的 α 混合并可在像素饱和后提前终止；反向复用排序结果从后到前遍历，将最终累积不透明度作为“缓存”反推中间量，从而实现近似恒定显存的可微训练。

5.4 3D 高斯表示与参数化

3D Gaussian Splatting (3DGS) 使用一组带属性的三维高斯来显式表示场景。对单个高斯，可写为

$$\mathcal{G}(\mathbf{x}) = \alpha \cdot \exp\left(-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1}(\mathbf{x} - \boldsymbol{\mu})\right), \quad (27)$$

其中 $\boldsymbol{\mu} \in \mathbb{R}^3$ 为中心， $\boldsymbol{\Sigma} \in \mathbb{R}^{3 \times 3}$ 为正定协方差矩阵， α 为不透明度或密度相关系数，颜色可由 RGB 或球谐系数参数化。

为了保证 $\boldsymbol{\Sigma}$ 正定，实践中常采用

$$\boldsymbol{\Sigma} = \mathbf{R} \mathbf{S} \mathbf{S}^\top \mathbf{R}^\top, \quad (28)$$

其中 $\mathbf{R} \in SO(3)$ 为旋转矩阵， $\mathbf{S} = \text{diag}(s_x, s_y, s_z)$ 为尺度矩阵。3DGS 的优化过程即是在多视角图像监督下对 $(\boldsymbol{\mu}, \mathbf{R}, \mathbf{S}, \alpha, \text{color})$ 等参数做梯度更新。

5.5 Splatting 与可微渲染

在渲染时，首先将三维高斯按当前相机位姿投影到二维像素平面，得到 2D 高斯（中心与协方差经过线性变换）。典型的协方差投影可写为

$$\boldsymbol{\Sigma}' = \mathbf{J} \mathbf{W} \boldsymbol{\Sigma} \mathbf{W}^\top \mathbf{J}^\top, \quad (29)$$

其中 $\mathbf{W}$ 为世界到相机的变换， $\mathbf{J}$ 为透视投影的雅可比近似；取 $\boldsymbol{\Sigma}'$ 的左上 2×2 子矩阵即可得到屏幕空间的 2D 高斯协方差。随后再按照深度从远至近排序，对每个像素做 alpha blending：

$$\mathbf{C}_{\text{out}} = \sum_k \tilde{\alpha}_k \left(\prod_{j < k} (1 - \tilde{\alpha}_j) \right) \mathbf{c}_k, \quad (30)$$

其中 $\tilde{\alpha}_k$ 为第 k 个高斯在该像素处的透明度权重， $\mathbf{c}_k$ 为其颜色。

与体渲染的等价关系 把体密度视作沿光线的“吸收”，NeRF 的离散体渲染可写为

$$C = \sum_{i=1}^N T_i (1 - \exp(-\sigma_i \delta_i)) c_i, \quad T_i = \exp\left(-\sum_{j=1}^{i-1} \sigma_j \delta_j\right). \quad (31)$$

令 $\alpha_i = 1 - \exp(-\sigma_i \delta_i)$ ，则有 $T_i = \prod_{j < i} (1 - \alpha_j)$ ，上式即化为有序 α 混合形式；3DGS 通过对覆盖像素的高斯按深度排序并执行同构的混合，因此在成像模型层面与体渲染一致，而将主要计算从“光线步进”转移到“可见高斯的投影与混合”，带来数量级的实时性能收益。

这一过程是可微的，可直接用反向传播优化高斯参数。

与 NeRF 相比，3DGS 在保持较高重建质量的同时，大幅提高了渲染速度与交互效率，更适合实时查看、编辑与下游任务。

5.6 创新点小结

从“世界模型”的工程视角看，3DGS 的关键贡献可以概括为三点：(1) **表示层**：用各向异性 3D 高斯显式承载几何与外观，避免了 MLP+ 步进在空空间的无效计算；(2) **优化层**：引入基于梯度的克隆/分裂/剔除，实现表示容量的自适应分配；(3) **系统层**：瓦片化裁剪 + 一次排序 + 可微混合，使 1080p 级别的实时渲染成为常态，从而为交互式编辑、在线 SLAM/重定位以及后续 4D 动态扩展提供了更直接的落地路径。

5.7 4DGS 与动态场景

3DGS 解决了“静态场景高质量 + 实时渲染”的主要矛盾，但一旦场景随时间发生运动/形变，简单地为每一帧各自维护一套高斯集合会带来两类问题：(i) **存储与训练代价随帧数线性增长**；(ii) **帧间一致性缺失**（几何会“漂”，外观会“跳”）。4D Gaussian Splatting (4DGS) [8] 的一条代表性路线是：仅维护一套**规范空间** (canonical space) 的 3D 高斯，并学习一个**时空形变场**把它们映射到任意时间 t 的世界空间，从而在保持 3DGS 光栅化速度的同时，获得可控的时空一致性与更紧凑的存储。

5.7.1 规范高斯 + 时空形变场

设规范空间的高斯集合为 $G = \{(\boldsymbol{\mu}, \mathbf{R}, \mathbf{S}, \alpha, \boldsymbol{\theta}_{\text{sh}})\}$ ，其中 $(\boldsymbol{\mu}, \mathbf{R}, \mathbf{S})$ 控制几何（位置/旋转/尺度）， α 控制不透明度， $\boldsymbol{\theta}_{\text{sh}}$ 为球谐 (SH) 颜色系数。在时间 t ，形变场根据时空特征预测几何增量

$$\Delta \mathbf{x} = \phi_x(\mathbf{f}(\mathbf{x}, t)), \quad \Delta \mathbf{r} = \phi_r(\mathbf{f}(\mathbf{x}, t)), \quad \Delta \mathbf{s} = \phi_s(\mathbf{f}(\mathbf{x}, t)), \quad (32)$$

$$(\boldsymbol{\mu}(t), \mathbf{r}(t), \mathbf{s}(t)) = (\boldsymbol{\mu} + \Delta \mathbf{x}, \mathbf{r} + \Delta \mathbf{r}, \mathbf{s} + \Delta \mathbf{s}), \quad (33)$$

并得到时间戳 t 下的形变高斯

$$G'(t) = \{(\boldsymbol{\mu}(t), \mathbf{R}(t), \mathbf{S}(t), \alpha, \boldsymbol{\theta}_{\text{sh}})\}. \quad (34)$$

其中 $\mathbf{r}$ 可用四元数参数化（再转换为 $\mathbf{R}$ ）， $\mathbf{s}$ 为三维尺度向量（再形成对角矩阵 $\mathbf{S}$ ），与 3DGS 的正定协方差分解形式保持一致。

5.7.2 HexPlane 多平面时空编码

为了让形变场既“够表达”又“够快”，常用做法是把 4D 时空体素分解为多组 2D 平面并做多分辨率特征查询，典型选择包括覆盖 $(x, y), (x, z), (y, z), (x, t), (y, t), (z, t)$ 的六个平面（常被称为 HexPlane）。设第 l 个分辨率层的平面特征为 $\{R_l(i, j)\}$ ，则对给定 $(\mathbf{x}, t)$ 的特征可写为

$$\mathbf{f}_h(\mathbf{x}, t) = \bigcup_l \text{Fuse}\left(\{\text{interp}(R_l(i, j))\}_{(i, j) \in \{(x, y), (x, z), (y, z), (x, t), (y, t), (z, t)\}}\right), \quad (35)$$

其中 $\text{interp}(\cdot)$ 表示双线性插值查询, $\text{Fuse}(\cdot)$ 表示拼接/加和等融合方式。随后用轻量 MLP 得到形变场的编码特征:

$$\mathbf{f}_d = \phi_d(\mathbf{f}_h). \quad (36)$$

在实现上, ϕ_x, ϕ_r, ϕ_s 常采用**解耦多头解码**, 分别专注于平移/旋转/尺度, 减少“一个头学全部”带来的梯度干扰。

5.7.3 渲染与损失

得到 $G'(t)$ 后, 渲染仍可直接复用 3DGS 的可微泼溅算子:

$$\hat{I}(t) = S(M, G'(t)), \quad (37)$$

其中 $M = [\mathbf{R}, \mathbf{T}]$ 为相机外参 (与内参投影共同决定屏幕坐标), $S(\cdot)$ 为瓦片式可微光栅化与有序 α 混合。(注意: 有序 α 混合中透射率应为 $\prod_{j < k} (1 - \alpha_j)$, 与体渲染离散形式一致。)

监督上常用像素级重建 (L1) 加上时空正则 (如 TV 全变分):

$$\mathcal{L} = \|\hat{I}(t) - I(t)\|_1 + \lambda_{tv} \mathcal{L}_{tv}. \quad (38)$$

5.7.4 两阶段优化策略

动态场景中“几何先稳、再学动”往往更容易收敛。因此常见训练策略是先用静态目标对规范高斯预热若干迭代 (得到可靠的几何与外观初始化), 再开启形变场与高斯的联合优化; 配合密度控制与分辨率渐进 (progressive training), 可以显著降低大形变场景的训练不稳定。

5.7.5 要点小结

从世界模型角度, 4DGS 的价值在于: 它把“状态随时间演化”变成显式、可微、可渲染的对象, 并通过“规范表示 + 时空形变”将存储从 $O(tN)$ 压到近似 $O(N + F)$ (F 为形变场参数量), 为后续的动态理解、编辑与预测提供了更可控的几何载体。

6 语义层与世界记忆接口

6.1 2D 语义分割与像素级监督

语义层的第一步通常是对每张输入图像做 2D 语义分割。设某张图像尺寸为 $H \times W$, 类别数为 K , 语义分割网络输出每个像素的 logits:

$$\mathbf{z}_{uv} \in \mathbb{R}^K, \quad (u, v) \in \{1, \dots, W\} \times \{1, \dots, H\}. \quad (39)$$

经过 softmax 得到类别概率

$$p(y_{uv} = k) = \frac{\exp(z_{uv}^{(k)})}{\sum_{k'} \exp(z_{uv}^{(k')})}, \quad (40)$$

训练时使用交叉熵损失：

$$\mathcal{L}_{\text{seg}} = -\frac{1}{HW} \sum_{u,v} \log p(y_{uv}^*), \quad (41)$$

其中 y_{uv}^* 为标注的真值类别。

在工程落地中，通常会对预处理后的图像批量生成像素级语义 label map，并可选汇总每张图的类别统计等元数据（例如用一个独立脚本完成这一阶段）。

6.2 3D 语义融合：从图像到点云

在已知 COLMAP 稀疏点云与其多视图观测的前提下，可将 2D 语义标签投票到 3D 点上，得到“带语义的点云”。设某个 3D 点 $\mathbf{X}$ 在若干图像中的投影像素为 $\{(u_i, v_i)\}$ ，对应的 2D 语义标签为 $\{y_i\}$ ，则可定义该点的 3D 语义标签为

$$\hat{y}(\mathbf{X}) = \arg \max_k \sum_i w_i \mathbf{1}[y_i = k], \quad (42)$$

其中 $\{w_i\}$ 为基于视角、深度或置信度的权重。

在一种常见实现中，可将融合后的 3D 语义点信息持久化为 JSON（或数据库），并提供按类别、按 3D 区域、按查询点的检索接口。

6.3 语义 NeRF 与语义 3DGS

在此基础上，可以在辐射场与 3DGS 层面进一步引入语义监督。

语义 NeRF： 对每个采样点，NeRF 模型除了输出 $(\mathbf{c}, \sigma)$ 外，还预测语义 logits $\mathbf{s} \in \mathbb{R}^K$ 。在体渲染过程中，同时对 RGB 与语义进行加权积分：

$$\hat{\mathbf{C}}(\mathbf{r}) = \sum_i w_i \mathbf{c}_i, \quad (43)$$

$$\hat{\mathbf{s}}(\mathbf{r}) = \sum_i w_i \mathbf{s}_i, \quad (44)$$

其中 w_i 为与密度相关的体渲染权重。对每条射线的语义标签 y^* 使用交叉熵损失：

$$\mathcal{L}_{\text{sem-NeRF}} = -\frac{1}{N} \sum_{\mathbf{r}} \log \frac{\exp(\hat{\mathbf{s}}_{y^*}(\mathbf{r}))}{\sum_k \exp(\hat{\mathbf{s}}_k(\mathbf{r}))}. \quad (45)$$

总损失为 RGB 与语义损失的加权和。工程上常将语义 NeRF 实现为在 NeRF 输出头部附加分类分支，并与 RGB 渲染联合训练。

语义 3DGS: 类似地, 可在每个高斯上附加语义 logits, 渲染语义图并用 2D 标签监督。由于几何与颜色已由基础 3DGS 学得, 语义头的训练可以在冻结几何与 RGB 的条件下进行, 从而提高优化稳定性。

6.4 相机可控视频生成与 3D 几何记忆: WorldStereo[11]

在更接近“世界模型”的场景中, 我们不仅关心单场景的静态几何与辐射场重建, 还需要在 **相机可控生成** (camera-guided generation) 与 **可重建性** (reconstructability) 之间取得平衡。WorldStereo (*WorldStereo: Bridging Camera-Guided Video Generation and Scene Reconstruction via 3D Geometric Memories*) 提出一种“先生成, 后重建”的工作流: 先利用带几何记忆的相机可控视频扩散模型生成跨视角一致的视频序列, 再以前馈方式从一致视频中恢复完整的 3D 点云, 从而把“生成”与“重建”连接成一个闭环。

6.4.1 研究背景与挑战

相机可控视频扩散模型 (Video Diffusion Models, VDMs) 在多视角一致性与长序列生成上存在典型瓶颈:

1. **多视角内容一致性不足:** 跨视角细节漂移会直接放大到 3D 重建的歧义与模糊;
2. **质量与成本的两难:** 长序列高质量生成通常意味着更长的去噪链与更高的显存/时间开销;
3. **泛化与效率难兼顾:** 强控制往往依赖重型模块或联合微调, 工程落地成本高。

WorldStereo 的关键思想是引入两类互补的“几何记忆”: **全局几何记忆** (Global Geometric Memory, GGM) 负责提供粗粒度的全局结构锚点, **空间立体记忆** (Spatial Stereo Memory, SSM) 负责提供细粒度跨视角对应与局部一致性。

6.4.2 整体框架: Multi-Bi-Mem 生成与重建闭环

整体流程可以概括为:

1. **初始化几何:** 由单张图像/全景图经单目深度估计得到初始点云, 并构建 2D 记忆与 3D 缓存;
2. **多轨迹双向生成:** 通过 GGM + SSM 引导 VDM 生成多条中等长度、双向扩展的相机轨迹视频;
3. **记忆增量更新:** 将新生成帧的内容与点云对齐后写回记忆库与 3D 缓存;
4. **前馈 3D 重建:** 基于一致视频重建更完整的点云/几何;
5. **推理加速:** 采用解耦式分布匹配蒸馏 (DMD) 将多步去噪压缩为少步推理。

该设计的工程直觉是：与其强迫单条超长轨迹覆盖所有视角，不如用多条双向轨迹分担覆盖，再用几何记忆维持一致性。这与“世界记忆”的抽象非常贴合：记忆不是一次性写死，而是随生成与重建不断增量更新。

6.4.3 关键模块与公式

(1) 参考帧点云生成： 通过单目深度反投影，将像素映射到世界坐标，得到度量级几何先验：

$$\mathbf{X}_{\text{pcd}}(x) \simeq \mathbf{R}_{c \rightarrow w} D(x) \mathbf{K}^{-1} \hat{\mathbf{x}}, \quad (46)$$

其中 $\mathbf{R}_{c \rightarrow w}$ 为相机到世界的位姿变换， $D(x)$ 为深度估计， $\mathbf{K}$ 为相机内参， $\hat{\mathbf{x}}$ 为像素齐次坐标。

(2) 全局几何记忆 (GGM) 的点云扩展： 将参考帧点云与缓存中的其他视图点云对齐并拼接，构建统一全局先验：

$$\mathbf{X}_{\text{pcd}}^g = [\mathbf{X}_{\text{pcd}}, \hat{\mathbf{X}}_{\text{pcd}}]. \quad (47)$$

推理阶段 $\hat{\mathbf{X}}_{\text{pcd}}$ 来自 3D 缓存，经 Umeyama 变换对齐到参考坐标系；训练阶段引入随机掩码以减轻“记忆过拟合”，提升跨场景泛化。

(3) 空间立体记忆 (SSM) 的特征融合： 将目标/参考视图的隐特征与“对应点图”的几何特征融合，为受限注意力提供输入：

$$\mathbf{z}_{\text{stitch}} = [\mathbf{z}_{\text{tar}}; \mathbf{z}_{\text{ref}}], \quad (48)$$

$$\hat{\mathbf{z}}_{\text{pm}} = [\hat{\mathbf{z}}_{\text{tar}}; \hat{\mathbf{z}}_{\text{ref}}], \quad (49)$$

$$\mathbf{z}_{\text{ssm}} = \mathbf{z}_{\text{stitch}} + \hat{\mathbf{z}}_{\text{pm}}. \quad (50)$$

其中 $\mathbf{z}_{\text{tar}}, \mathbf{z}_{\text{ref}}$ 为 3D-VAE 隐特征， $\hat{\mathbf{z}}_{\text{tar}}, \hat{\mathbf{z}}_{\text{ref}}$ 由编码 3D 世界坐标的点图 (point map) 得到。受限注意力 (restricted attention) 进一步限制跨视角关联的搜索空间，更像经典立体匹配中的“局部视差搜索”，但工作在扩散隐空间中。

(4) 解耦式 DMD 蒸馏： 冻结控制分支，仅蒸馏 VDM 主干，以少步推理逼近教师的得分函数差异，典型形式可写作

$$\nabla \mathcal{L}_{\text{DMD}} = -\mathbb{E}_t \left(\int (s_{\text{real}}(x_t, t) - s_{\text{fake}}(x_t, t)) \frac{dx_t}{d\theta} dz \right), \quad (51)$$

其中 $t \sim U(0, 1)$ ， s_{real} 为冻结教师得分函数， s_{fake} 为学生得分函数， $x = G_{\theta}(z)$ 表示学生生成器输出。

6.4.4 创新点与技术价值

- **范式层面：**提出 Multi-Bi-Mem 的“多条中等长度双向轨迹 + 双几何记忆”生成范式，在视角覆盖、一致性与推理效率之间取得更可控的折中。
- **结构层面：**GGM 提供全局结构锚点，SSM 提供细节一致性约束，二者互补，使“可控生成”对“可重建”更友好（生成结果更适合下游 SfM/MVS 或前馈重建）。
- **工程层面：**解耦式 DMD 蒸馏在不破坏控制分支的前提下加速去噪链，让相机可控生成更接近可用的推理延迟。
- **评估层面：**引入面向 VDM 单视图/少视图 3D 重建的标准化评估流程（如 F1、AUC、相机误差等），有利于把“生成质量”与“几何可用性”同时纳入比较。

从本综述的视角看，WorldStereo 的价值在于提供了一条更“系统工程”的路径：用几何记忆把相机可控生成变成可增量更新的世界状态，从而让“生成”与“重建”互为监督与校正信号。

6.5 演化式全景世界生成与显式 3D 记忆：EvoWorld[10]

在“相机可控生成 + 几何记忆”之外，另一条更偏向“具身探索”的路线是：**把生成过程本身变成一个带显式 3D 记忆的闭环系统**。EvoWorld (*EvoWorld: Evolving Panoramic World Generation with Explicit 3D Memory*) 聚焦于全景 (panoramic / 360) 场景的长时序递归生成：当相机回环到已访问区域时，若缺少显式 3D 表征，模型往往会出现严重几何漂移（物体消失、结构改变），导致“空间一致性崩塌”。EvoWorld 的核心思路是把 **3D 重建与 视频扩散生成** 做成一个可迭代的闭环，并用显式点云记忆持续约束生成过程。

6.5.1 问题设定与闭环流程

给定初始全景图 x_0 ，EvoWorld 维护一个随时间演化的显式 3D 点云记忆 $\mathcal{M}_t$ 。在第 t 步，智能体执行相机控制动作 a_t ，得到目标位姿（平移与旋转） (δ_t, α_t) ，并按“重建 → 重投影引导 → 生成 → 记忆更新”的循环推进世界状态：

1. **初始化：**由 x_0 构建初始 360 世界与点云记忆 $\mathcal{M}_1$ ；
2. **几何引导：**将 $\mathcal{M}_t$ 重投影到目标视角得到几何引导图 r_t ；
3. **条件生成：**在多条件（语义/历史帧/位姿/几何引导）下采样生成全景视频片段 x_t ；
4. **记忆演化：**将新生成的视频与位姿送入重建模块，更新得到 $\mathcal{M}_{t+1}$ 。

6.5.2 关键公式：记忆重投影、扩散采样与记忆更新

(1) 3D 记忆的重投影渲染： 将时刻 t 的点云记忆 $\mathcal{M}_t$ 通过由位姿 (δ_t, α_t) 定义的透视/球面投影算子 $\mathcal{T}$ ，渲染到目标视角形成几何引导图：

$$r_t = \mathcal{T}(\mathcal{M}_t; \delta_t, \alpha_t). \quad (52)$$

工程实现上， $\mathcal{T}$ 可由 GPU 光栅化完成：包括坐标投影、深度可见性求解与像素赋值；并将结果转换为等矩形（equirectangular）全景格式以便与扩散模型输入对齐。

(2) 条件全景视频扩散采样： 以历史末帧 x_{t-1}^S 、位姿条件与几何引导图 r_t 作为条件，从参数为 θ 的全景视频扩散模型中采样生成新片段：

$$x_t \sim p_\theta(x \mid x_{t-1}^S, \delta_t, \alpha_t, r_t), \quad (53)$$

其中 $x_t = (x_t^0, x_t^1, \dots, x_t^S)$ 为包含 $S+1$ 帧的短视频片段。典型做法是将 x_{t-1}^S 经编码器嵌入后通过交叉注意力注入，并将 r_t 与噪声潜变量在通道维拼接输入去噪网络，从而把“显式几何约束”变为可学习条件。

(3) 3D 记忆的演化更新： 将历史生成序列与相机位姿输入重建函数 $\mathcal{R}$ ，得到下一时刻记忆：

$$\mathcal{M}_{t+1} = \mathcal{R}(x_{0:t}, \delta_{0:t}, \alpha_{0:t}). \quad (54)$$

为保证长时序下的可扩展性，可只选取与当前位置空间邻近的一小段帧参与重建（例如限制帧数 ≤ 100 ），从而实现近似恒定的显存/内存占用。

6.5.3 全景球面与位姿嵌入：球面 Plücker 表达

全景场景满足 $W = 2H$ 的等矩形展开。球面极坐标 (ϕ, θ) 与像素 (u, v) 的互相映射可写为：

$$f_{S \rightarrow \mathcal{P}}(\phi, \theta) = \left(\frac{W}{2\pi}(\phi + \pi), \frac{H}{\pi} \left(\frac{\pi}{2} - \theta \right) \right), \quad (55)$$

$$f_{\mathcal{P} \rightarrow S}(u, v) = \left(\frac{2\pi u}{W} - \pi, \frac{\pi}{2} - \frac{\pi v}{H} \right). \quad (56)$$

在位姿条件上，EvoWorld 采用对全景球面更友好的“球面 Plücker”光线嵌入：

$$\varphi_t = [\mathbf{d}, \mathbf{c}_t \times \mathbf{d}] \in \mathbb{R}^{(S+1) \times 6}, \quad (57)$$

其中 $\mathbf{d}$ 为从球心指向球面方向的单位光线方向， $\mathbf{c}_t$ 为相机中心。直觉上，这是把“视角控制”从平面相机的像素光线场，改成球面光线场，更契合 360 数据的几何结构。

6.5.4 创新点与价值总结

- **闭环范式**：显式 3D 记忆与扩散生成深度耦合，使生成过程具有“可积累的世界状态”，从根源缓解自回归长序列的误差累积与回环漂移。
- **全景适配**：通过球面坐标映射与球面 Plücker 位姿嵌入，提升全景相机控制精度与一致性。
- **工程可扩展**：局部检索与邻近帧重建使得长序列推理可在近似恒定资源下运行。
- **基准数据**：构建 Spatial360 全景数据集与评估体系，为“长时序可探索全景世界生成”提供可复现实验载体。

从本综述的技术谱系看，EvoWorld 更像是把“显式几何记忆”从生成模型的辅助模块，上升为世界状态转移的核心变量：渲染与重建不再是离线后处理，而是驱动生成稳定性的硬约束。

7 统一静态场景状态与世界模型视角

为了在世界模型实验中复用同一真实场景，可以通过静态场景状态 (*Scene State*) 将多种表示统一到一个 JSON 描述中，例如用类似 `world_state.<scene>.json` 的文件来集中记录该场景的全部资产与元数据。其核心思想包括：

- 统一的场景 ID、根目录与世界坐标系说明；
- 集中记录 COLMAP、Nerfstudio/NeRF、3DGS 与 semantics 各自的数据与模型路径；
- 通过 `SceneState` 与 `SemanticScene` 等数据结构，提供按类别、按 3D 区域、按点的可查询接口。

从更宏观的角度看，几何层保证物理一致性，辐射场层保证真实感，显式层保证效率与可编辑性，语义层与 *Scene State* 则将这些表示组织成统一的世界记忆单元。这正是面向世界模型的 3D/360 重建技术路径的核心理念。

8 评估指标体系：几何、渲染与世界模型导向

面向世界模型的 3D/360 重建不应只用“看起来是否逼真”来评估。更稳妥的做法是把评估拆成三类：

几何与位姿、

新视图渲染、

世界模型导向能力。本节给出一套能直接落到实验记录表与 benchmark 脚本中的指标体系。

8.1 几何与位姿指标 (Geometry / Pose)

重投影误差 (Reprojection Error)。 SfM/BA 过程中最常见的局部指标是像素域重投影误差：

$$e_{ij} = \|\pi(\mathbf{R}_i \mathbf{X}_j + \mathbf{t}_i; \boldsymbol{\theta}_i) - \mathbf{p}_{ij}\|_2. \quad (58)$$

它能快速暴露匹配/畸变/内参不一致等问题，但并不直接等价于轨迹漂移或全局尺度稳定性。

ATE/RPE (轨迹误差)。 当存在位姿真值（或可对齐的参考轨迹）时，常用绝对轨迹误差 ATE 与相对位姿误差 RPE[9]：

$$\text{ATE} = \sqrt{\frac{1}{N} \sum_{i=1}^N \|\mathbf{t}_i - \mathbf{t}_i^*\|_2^2}, \quad (59)$$

$$\text{RPE}(\Delta) = \text{Error}((\mathbf{T}_i^{-1} \mathbf{T}_{i+\Delta}), (\mathbf{T}_i^{*-1} \mathbf{T}_{i+\Delta}^*)), \quad (60)$$

其中 $\mathbf{T}_i \in SE(3)$ 为估计位姿， $\mathbf{T}_i^*$ 为真值位姿；RPE 常用于刻画随时间/步长累积的漂移。

点云/表面误差。 若有高精度几何真值（激光扫描/深度传感器），可对重建点云/网格计算 Chamfer Distance、F-score 等几何指标。这些指标更直接反映几何可用性，但对对齐、裁剪与可见性区域定义较敏感。

8.2 新视图合成指标 (Rendering / NVS)

PSNR/SSIM/LPIPS。 新视图合成通常报告 PSNR、SSIM 与感知距离 LPIPS。以 PSNR 为例，给定预测图像 $\hat{\mathbf{I}}$ 与真值 $\mathbf{I}$ ：

$$\text{MSE} = \frac{1}{HW} \sum_{u,v} \|\hat{\mathbf{I}}_{uv} - \mathbf{I}_{uv}\|_2^2, \quad \text{PSNR} = 10 \log_{10} \frac{L^2}{\text{MSE}}, \quad (61)$$

其中 L 为像素动态范围（如 $L = 1$ 或 255）。

360 场景的面积加权。 等矩形投影在极区被拉伸，因此直接对像素均匀平均会高估极区误差的重要性。实践中可对纬度 θ 使用面积权重 $w(\theta) = \cos \theta$ 进行加权平均，以更接近球面真实面积分布。

8.3 效率与资源 (Efficiency)

世界模型往往要求交互性，因此需要单独记录：

- **训练时间：**达到指定质量阈值所需的 wall-clock 时间、迭代数与 GPU 小时；
- **渲染速度：**在指定分辨率下的 FPS / ms-per-frame；
- **显存与模型大小：**峰值显存、参数量、导出资产大小（高斯数量/体素/网格面数等）。

例如 3DGS/4DGS 的关键优势之一就是实时渲染（通常 1080p 可达 30fps 级别）[7, 8]。

8.4 世界模型导向指标 (World-Model-Oriented)

当目标是“可查询、可重定位、可增量更新”的世界记忆时，建议至少补充以下类指标：

- **可重定位性 (Relocalization)：**从新视角图像估计相机位姿的成功率/精度（例如 PnP-in-map 成功率、ATE）；
- **回环一致性 (Loop Consistency)：**回到历史位置时，局部结构是否可对齐（局部 ATE/RPE、回环匹配召回）；
- **可查询性 (Queryability)：**语义查询/空间检索的准确率（3D IoU、mIoU、区域检索召回）；
- **可编辑性与可控性：**对局部对象修改后是否能保持全局一致（编辑后渲染指标变化、结构破坏率）；
- **增量更新代价：**新增观测/帧后更新所需时间与受影响区域比例（越局部越好）。

8.5 指标与产物对照表（建议直接贴到实验记录模板）

指标类别	代表指标	需要的输入/产物
几何/位姿	重投影误差、 ATE/RPE、 Chamfer/F-score	相机位姿、稀疏/稠密点云、（可选）真值轨迹/几何
渲染质量	PSNR、SSIM、 LPIPS、（360 加权） PSNR	测试视角真值图像与渲染结果、 遮罩/可见性定义
效率	训练时间、FPS、显存 峰值、资产大小	训练日志、渲染脚本、统计高 斯/网格规模
世界模型导向	重定位成功率、回环一 致性、3D 语义 mIoU、 增量更新代价	可查询的场景表示（Scene State/语义点云/高斯）、评测任 务脚本

9 结语

本文以 3D_Reconstruction_ing 仓库为背景，围绕几何、辐射场、显式高斯表示与语义层，梳理了从传统三维重建走向世界模型的关键数学原理与算法框架。配合工程实践文档（另见配套的工程实现教程 L^AT_EX 文档），读者可以一方面从理论上理解各层组件的角色与联系，另一方面在真实数据集（如 Mip-NeRF 360）上动手打通整条 Pipeline。

参考文献

- [1] Johannes L. Schönberger and Jan-Michael Frahm. Structure-from-Motion Revisited. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2016.
- [2] Johannes L. Schönberger, Enliang Zheng, Jan-Michael Frahm, and Marc Pollefeys. Pixelwise View Selection for Unstructured Multi-View Stereo. In *European Conference on Computer Vision (ECCV)*, 2016.
- [3] Juho Kannala and Sami S. Brandt. A Generic Camera Model and Calibration Method for Conventional, Wide-Angle, and Fish-Eye Lenses. *IEEE Transactions on Pattern Analysis and Machine Intelligence (TPAMI)*, 28(8):1335–1340, 2006.
- [4] Ben Mildenhall, Pratul P. Srinivasan, Matthew Tancik, Jonathan T. Barron, Ravi Ramamoorthi, and Ren Ng. NeRF: Representing Scenes as Neural Radiance Fields for View Synthesis. In *European Conference on Computer Vision (ECCV)*, 2020.
- [5] Jonathan T. Barron, Ben Mildenhall, Dor Verbin, Pratul P. Srinivasan, and Peter Hedman. Mip-NeRF 360: Unbounded Anti-Aliased Neural Radiance Fields. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2022.
- [6] Matthew Tancik, Ethan Weber, Evonne Ng, Ruilong Li, Brent Yi, Justin Kerr, Terrance Wang, Alexander Kristoffersen, Jake Austin, Kamyar Salahi, Abhik Ahuja, David McAllister, Angjoo Kanazawa. Nerfstudio: A Modular Framework for Neural Radiance Field Development. In *ACM SIGGRAPH Conference Proceedings*, 2023. (arXiv:2302.04264)
- [7] Bernhard Kerbl, Georgios Kopanas, Thomas Leimkühler, and George Drettakis. 3D Gaussian Splatting for Real-Time Radiance Field Rendering. *ACM Transactions on Graphics (TOG)*, 42(4), 2023. (arXiv:2308.04079)
- [8] Guanjun Wu, Taoran Yi, Jiemin Fang, Lingxi Xie, Xiaopeng Zhang, Wei Wei, Wenyu Liu, Qi Tian, and Xinggang Wang. 4D Gaussian Splatting for Real-Time Dynamic Scene Rendering. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2024. (arXiv:2310.08528)
- [9] Jürgen Sturm, Nikolas Engelhard, Felix Endres, Wolfram Burgard, and Daniel Cremers. A Benchmark for the Evaluation of RGB-D SLAM Systems. In *IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, 2012.

- [10] Jiahao Wang, Luoxin Ye, TaiMing Lu, Junfei Xiao, Jiahan Zhang, Yuxiang Guo, Xijun Liu, Rama Chellappa, Cheng Peng, Alan Yuille, and Jieneng Chen. EvoWorld: Evolving Panoramic World Generation with Explicit 3D Memory. arXiv:2510.01183, 2025.
- [11] Yisu Zhang, Chenjie Cao, Tengfei Wang, Xuhui Zuo, Junta Wu, Jianke Zhu, and Chunchao Guo. WorldStereo: Bridging Camera-Guided Video Generation and Scene Reconstruction via 3D Geometric Memories. arXiv:2603.02049, 2026.